

ML Under Modern Optimization Lens - Aula 2 - Exercícios

Giovanni Amorim

Abril, 2023

1 Experimentos com regressão esparsa

As duas implementações do modelo de regressão esparsa foram avaliadas em 3 bases de dados diferentes:

1. **winequality-red**: Qualidade de vinho tinto por atributos químicos e gastronômicos.
2. **Twitter**: Alcance de tópicos na rede social Twitter
3. **ObesityDataSet-raw-and-data-sinthetic**: Nível de obesidade a partir de características físicas e médicas

Para cada base, foram comparados os tempos de busca pela solução das duas implementações, além das soluções, que deveriam ser iguais. As comparações de tempo mostraram diferenças pequenas:

Base de dados	Tempo 1 (s)	Tempo 2 (s)
winequality-red	0.034	0.007
Twitter	0.025	0.023
ObesityDataSet	0.019	0.021

As soluções encontradas, como esperado, foram as mesmas independente da implementação.

2 Seleção de k e comparação com Lasso e ADA-Lasso

Em um segundo momento, foi utilizada a metodologia de K-fold cross-validation ($k=7$) para a seleção da quantidade máxima de regressores do modelo. Utilizando a base de "winequality-red" e mantendo o parâmetro λ igual a 0.1, o espaço avaliado foi de 1 a 10 e $k=8$ foi finalmente selecionado. Após esse momento, foram comparadas as performances em teste entre os modelos:

Modelo	MSE	$ \beta _0$
Sparse	0.5923	8
Lasso	0.6262	4
ADA-Lasso	0.6038	6

Conclusões

1. Não foi identificada diferença significativa entre os tempos de solução das diferentes implementações do modelo esparsos. Entretanto, vale notar que os testes não foram extensivos.
2. O espaço de seleção do hiper-parâmetro k do modelo pode ser mais facilmente avaliado do que outros parâmetros de regularização.
3. O modelo esparsos se mostrou competitivo tanto em termos de custo de processamento quanto em performance quando comparado com modelos Lasso e ADA Lasso.